

Содержание

- Операции передачи данных между двумя процессорами
 - Режимы передачи данных
 - Организация неблокирующих обменов данными между процессорами
 - Одновременное выполнение передачи и приема
- Коллективные операции передачи данных
 - Обобщенная передача данных от всех процессов одному процессу
 - Обобщенная передача данных от одного процесса всем процессам
 - Общая передача данных от всех процессов всем процессам
 - Дополнительные операции редукции данных
- Производные типы данных в MPI
 - Способы конструирования производных типов данных
- Заключение

Режимы передачи данных...

- Стандартный (Standard):
 - обеспечивается функцией MPI_Send,
 - на время выполнения функции процесс-отправитель сообщения блокируется,
 - после завершения функции буфер может быть использован повторно,
 - состояние отправленного сообщения может быть различным сообщение может располагаться в процессе-отправителе, может находиться в процессе передачи, может храниться в процессе-получателе или же может быть принято процессом-получателем при помощи функции MPI_Recv.

Режимы передачи данных...

- Синхронный (Synchronous) режим
 - завершение функции отправки сообщения происходит только при получении от процесса-получателя подтверждения о начале приема отправленного сообщения:

MPI_Ssend – функция отправки сообщения в синхронном режиме

- Режим передачи по готовности (Ready)
 - может быть использован только, если операция приема сообщения уже инициирована. Буфер сообщения после завершения функции отправки сообщения может быть повторно использован.

MPI_Rsend – функция отправки сообщения в режиме по готовности

Режимы передачи данных...

- Буферизованный (Buffered) режим
 - используются дополнительные системные буферы для копирования в них отправляемых сообщений; функция отправки сообщения завершается сразу же после копирования сообщения в буфер,

```
MPI_Bsend – функция отправки сообщения в буферизованном режиме,
```

 Для использования буферизованного режима передачи должны быть создан и передан MPI буфер памяти:

```
int MPI_Buffer_attach(void *buf, int size),
где
- buf - буфер памяти для буферизации сообщений,
- size - размер буфера.
```

 После завершения работы с буфером он должен быть отключен от МРІ при помощи функции:

```
int MPI_Buffer_detach(void *buf, int *size)
```

Режимы передачи данных...

- Режим передачи *по готовности* формально является наиболее быстрым, но используется достаточно редко, т.к. обычно сложно гарантировать готовность операции приема,
- Стандартный и буферизованный режимы также выполняются достаточно быстро, но могут приводить к большим расходам ресурсов (памяти), могут быть рекомендованы для передачи коротких сообщений,
- Синхронный режим является наиболее медленным, т.к. требует подтверждения приема. В тоже время, этот режим наиболее надежен можно рекомендовать его для передачи длинных сообщений.

Организация неблокирующих обменов данными между процессорами...

- *Блокирующие функции* приостанавливают выполнение процессов до момента завершения работы вызванных функций,
- *Неблокирующие функции* обмена данными выполняются без блокировки процессов для совмещения процессов передачи сообщений и вычислений:
 - Более сложен для использования,
 - Может в значительной степени уменьшить потери эффективности параллельных вычислений из-за медленных коммуникационных операций.

Организация неблокирующих обменов данными между процессорами...

Наименование неблокирующих аналогов образуется из названий соответствующих функций путем добавления префикса I (Immediate).

Организация неблокирующих обменов данными между процессорами...

• Проверка состояния выполняемой неблокирующей операции передачи данных выполняется при помощи функции:

Операция проверки является неблокирующей.

Организация неблокирующих обменов данными между процессорами...

• Возможная схема вычислений и выполнения неблокирующей операции обмена:

```
MPI_Isend(buf,count,type,dest,tag,comm,&request);
...
do {
    ...
    MPI_Test(&request,&flag,&status);
} while (!flag);
```

Блокирующая операция ожидания завершения операции:

```
int MPI_Wait( MPI_Request *request, MPI_status *status);
```

Организация неблокирующих обменов данными между процессорами

 Дополнительные функций проверки и ожидания неблокирующих операций обмена:

```
    MPI_Testall - проверка завершения всех перечисленных операций обмена,
    MPI_Waitall - ожидание завершения всех операций обмена,
    MPI_Testany - проверка завершения хотя бы одной из перечисленных операций обмена,
    MPI_Waitany - ожидание завершения любой из перечисленных операций обмена,
    MPI_Testsome - проверка завершения каждой из перечисленных операций обмена,
    MPI_Waitsome - ожидание завершения хотя бы одной из перечисленных операций обмена и оценка состояния по всем операциям.
```

Одновременное выполнение передачи и приема

Функция, позволяющая эффективно одновременно выполнить передачу и прием данных:

```
int MPI_Sendrecv(
  void *sbuf, int scount, MPI_Datatype stype, int dest, int stag,
  void *rbuf, int rcount, MPI_Datatype rtype, int source, int rtag,
  MPI_Comm comm, MPI_Status *status),

где
- sbuf, scount, stype, dest, stag - параметры передаваемого сообщения,
- rbuf, rcount, rtype, source, rtag - параметры принимаемого сообщения,
- comm - коммуникатор, в рамках которого выполняется передача данных,
- status - структура данных с информацией о результате выполнения операции.
```

• В случае, когда сообщения имеют одинаковый тип, имеется возможность использования единого буфера:

```
int MPI_Sendrecv_replace(void *buf, int count, MPI_Datatype type,
  int dest, int stag, int source, int rtag, MPI_Comm comm,
  MPI_Status *status).
```

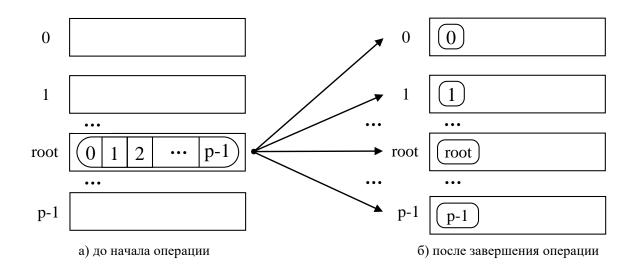
Под коллективными операциями в MPI понимаются операции данных, в которых принимают участие все процессы используемого коммуникатора

Обобщенная передача данных от одного процесса всем процессам...

• *Распределение данных* – ведущий процесс (*root*) передает

Обобщенная передача данных от одного процесса всем процессам

- Вызов MPI_Scatter при выполнении рассылки данных должен быть обеспечен в каждом процессе коммуникатора,
- *MPI_Scatter* передает всем процессам сообщения одинакового размера. Если размеры сообщений для процессов могут быть разными, следует использовать функцию *MPI_Scatterv*.

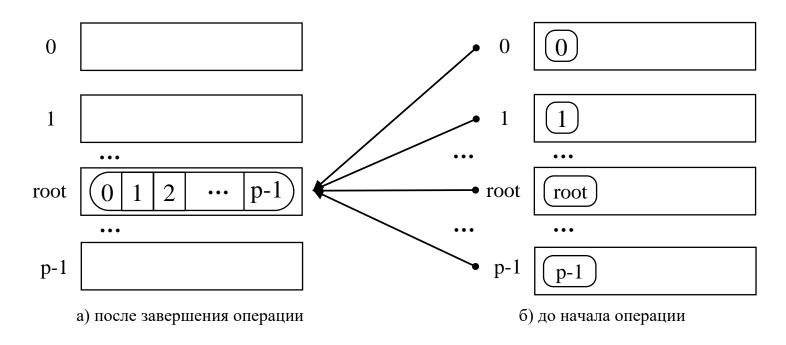


Обобщенная передача данных от всех процессов одному процессу...

• Передача данных от всех процессоров одному процессу (*сбор* данных) является обратной к операции распределения данных

Обобщенная передача данных от всех процессов одному процессу...

• *MPI_Gather* определяет коллективную операцию, и ее вызов при выполнении сбора данных должен быть обеспечен в каждом процессе коммуникатора



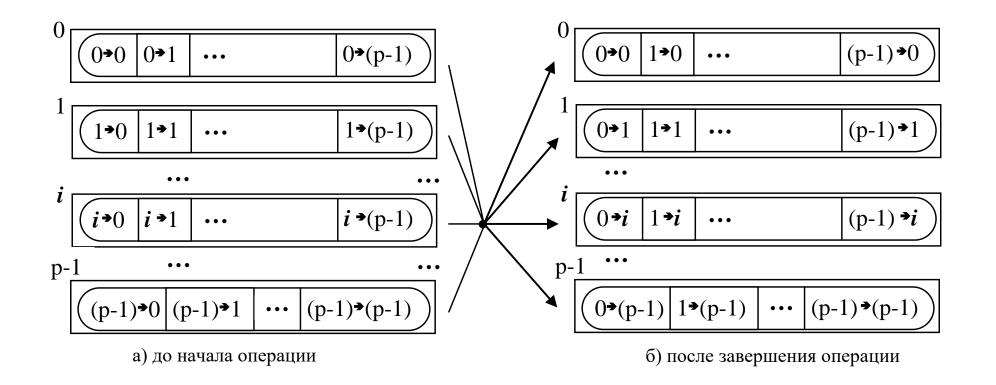
Обобщенная передача данных от всех процессов одному процессу

• *MPI_Gather* собирает данные на одном процессе. Для получения всех собираемых данных на каждом процессе нужно

```
int MPI_Allgather(void *sbuf, int scount, MPI_Datatype stype,
    void *rbuf, int rcount, MPI_Datatype rtype, MPI_Comm comm).
```

• В случае, когда размеры передаваемых процессами сообщений могут быть различны, для передачи данных необходимо использовать функции MPI_Gatherv и MPI_Allgatherv.

Общая передача данных от всех процессов всем процессам...



Обобщенная передача данных от всех процессов всем процессам

```
int MPI_Alltoall(void *sbuf,int scount,MPI_Datatype stype, void *rbuf,int rcount, MPI_Datatype rtype,MPI_Comm comm),
где

- sbuf, scount, stype - параметры передаваемых сообщений,
- rbuf, rcount, rtype - параметры принимаемых сообщений
- comm - коммуникатор, в рамках которого выполняется передача данных.
```

- Вызов функции *MPI_Alltoall* при выполнении операции общего обмена данными должен быть выполнен в каждом процессе коммуникатора,
- Вариант операции общего обмена данных, когда размеры передаваемых процессами сообщений могут быть различны обеспечивается при помощи функций MPI Alltoallv.

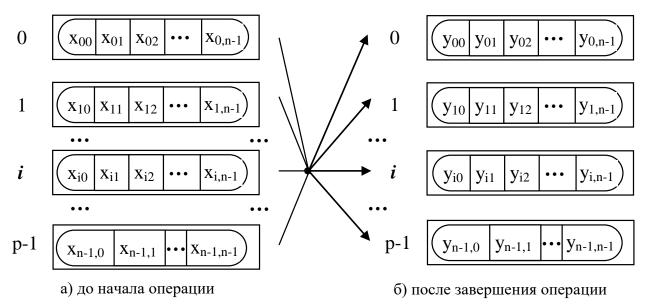
Дополнительные операции редукции данных...

- *MPI_Reduce* обеспечивает получение результатов редукции данных только на одном процессе,
- Функция MPI_AllReduce редукции и рассылки выполняет рассылку между процессами всех результатов операции редукции:

- Возможность управления распределением этих данных между процессами предоставляется функций *MPI_Reduce_scatter,*
- Функция MPI_Scan производит операцию сбора и обработки данных, при которой обеспечивается получение и всех частичных результатов редуцирования

Дополнительные операции редукции данных

• При выполнении функции *MPI_Scan* элементы получаемых сообщений представляют собой результаты обработки соответствующих элементов передаваемых процессами сообщений, при этом для получения результатов на процессе с рангом *i*, 0≤*i*<*n*, используются данные от процессов, ранг которых меньше или равен *i*



- Во всех ранее рассмотренных примерах использования функций передачи данных предполагалось, что сообщения представляют собой некоторый непрерывный вектор элементов предусмотренного в МРІ типа,
- В общем случае, необходимые к пересылке данные могут располагаться не рядом и состоять из разного типа значений:
 - разрозненные данные могут быть переданы с использованием нескольких сообщений (такой способ ведет к накоплению латентности множества выполняемых операций передачи данных),
 - разрозненные данные могут быть предварительно упакованы в формат того или иного непрерывного вектора (появление лишних операций копирования данных).

- Производный тип данных в MPI описание набора значений предусмотренного в MPI типа, значения могут не располагаться непрерывно по памяти:
 - Задание типа в МРІ принято осуществлять при помощи карты типа (type map) в виде последовательности описаний входящих в тип значений, каждое отдельное значение описывается указанием типа и смещения адреса месторасположения от некоторого базового адреса:

```
TypeMap = {(type<sub>0</sub>, disp<sub>0</sub>), (type<sub>1</sub>, disp<sub>1</sub>), ..., (type<sub>n-1</sub>, disp<sub>n-1</sub>)}
```

 Часть карты типа с указанием только типов значений именуется в МРІ сигнатурой типа:

```
TypeSignature = {type<sub>0</sub>, type<sub>1</sub>, ..., type<sub>n-1</sub>}
```

- Пример.
 - Пусть в сообщение должны входить значения переменных:

```
double a; /* адрес 24 */
double b; /* адрес 40 */
int n; /* адрес 48 */
```

 Тогда производный тип для описания таких данных должен иметь карту типа следующего вида:

```
{ (MPI_DOUBLE, 0),
  (MPI_DOUBLE, 16),
  (MPI_INT, 24)
}
```

- Для производных типов данных в MPI используется следующих ряд новых понятий:
 - нижняя граница типа:

$$lb (TypeMap) = \min_{i} (disp_{i})$$

верхняя граница типа:

$$ub\ (TypeMap) = \max_{j} (disp_{j} + sizeof(type_{j})) + \Delta$$

— *протяженность* типа (размер памяти в байтах, который нужно отводить для одного элемента производного типа):

$$extent (TypeMap) = ub (TypeMap) - lb (TypeMap)$$

— *размер* типа данных - это число байтов, которые занимают данные.

Различие в значениях протяженности и размера состоит в величине округления для выравнивания адресов.

• Для получения значения протяженности и размера типа в MPI предусмотрены функции:

```
int MPI_Type_extent ( MPI_Datatype type, MPI_Aint *extent );
int MPI_Type_size ( MPI_Datatype type, MPI_Aint *size );
```

 Определение нижней и верхней границ типа может быть выполнено при помощи функций:

```
int MPI_Type_lb ( MPI_Datatype type, MPI_Aint *disp );
int MPI_Type_ub ( MPI_Datatype type, MPI_Aint *disp );
```

• Важной и необходимой при конструировании производных типов является функция получения адреса переменной:

```
int MPI_Address ( void *location, MPI_Aint *address );
```

- Способы конструирования производных типов данных:
 - *Непрерывный* способ позволяет определить непрерывный набор элементов существующего типа как новый производный тип,
 - Векторный способ обеспечивает создание нового производного типа как набора элементов существующего типа, между элементами которого существуют регулярные промежутки по памяти. При этом, размер промежутков задается в числе элементов исходного типа,
 - *Индексный* способ отличается от векторного метода тем, что промежутки между элементами исходного типа могут иметь нерегулярный характер,
 - *Структурный* способ обеспечивает самое общее описание производного типа через явное указание карты создаваемого типа данных.

• Непрерывный способ конструирования:

— Как следует из описания, новый тип *newtype* создается как *count* элементов исходного типа *oldtype*. Например, если исходный тип данных имеет карту типа

```
{ (MPI_INT, 0), (MPI_DOUBLE, 8) },
```

то вызов функции MPI_Type_contiguous с параметрами

```
MPI_Type_contiguous (2, oldtype, &newtype);
```

приведет к созданию типа данных с картой типа:

```
{ (MPI_INT,0),(MPI_DOUBLE,8),(MPI_INT,16),(MPI_DOUBLE,24) }.
```

• Векторный способ конструирования...

 при векторном способе новый производный тип создается как набор блоков из элементов исходного типа, при этом между блоками могут иметься регулярные промежутки по памяти.

 Если интервалы между блоками задаются в байтах, а не в элементах исходного типа данных, следует использовать функцию:

• Векторный способ конструирования:

создание производных типов для описания подмассивов многомерных массивов

```
int MPI Type create subarray ( int ndims, int *sizes,
      int *subsizes, int *starts, int order,
      MPI Data type oldtype, MPI Datatype *newtype ),
где
- ndims - размерность массива,
- sizes - количество элементов в каждой размерности исходного
            массива,
- subsizes - количество элементов в каждой размерности
определяемого
            подмассива,
- starts - индексы начальных элементов в каждой размерности
             определяемого подмассива,
- order
          - параметр для указания необходимости
переупорядочения,
- oldtype - тип данных элементов исходного массива,
- newtype - новый тип данных для описания подмассива.
```

• Индексный способ конструирования:

 новый производный тип создается как набор блоков разного размера из элементов исходного типа, при этом между блоками могут иметься разные промежутки по памяти.

 Если интервалы между блоками задаются в байтах, а не в элементах исходного типа данных, следует использовать функцию:

```
int MPI_Type_hindexed ( int count, int blocklens[],
    MPI_Aint indices[],MPI_Data_type oldtype,MPI_Datatype *newtype);
```

- Индексный способ конструирования:
 - конструирования типа для описания верхней треугольной матрицы размером nxn:

- Структурный способ конструирования:
 - является самым общим методом конструирования производного типа данных при явном задании соответствующей карты типа:

- Объявление производных типов и их удаление:
 - перед использованием созданный тип должен быть объявлен :

```
int MPI_Type_commit (MPI_Datatype *type );
```

 При завершении использования производный тип должен быть аннулирован при помощи функции:

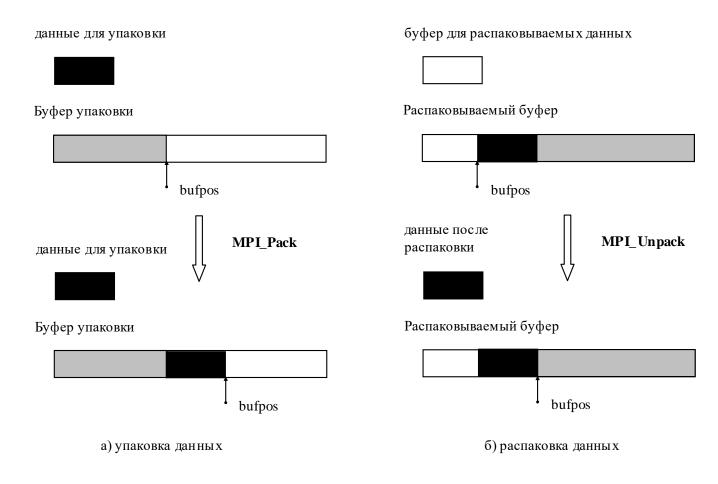
```
int MPI_Type_free (MPI_Datatype *type );
```

- Формирование сообщений при помощи упаковки и распаковки данных...
 - явный способ сборки и разборки сообщений, в которые могут входить значения разных типов и располагаемых в разных областях памяти:

```
int MPI_Pack (void *data, int count, MPI_Datatype type, void *buf, int bufsize, int *bufpos, MPI_Comm comm),
где
- data - буфер памяти с элементами для упаковки,
- count - количество элементов в буфере,
- type - тип данных для упаковываемых элементов,
- buf - буфер памяти для упаковки,
- buflen - размер буфера в байтах,
- bufpos - позиция для начала записи в буфер (в байтах от начала буфера),
- comm - коммуникатор для упакованного сообщения.
```

Производные типы данных в МРІ...

 Формирование сообщений при помощи упаковки и распаковки данных...



Производные типы данных в МРІ...

- Формирование сообщений при помощи упаковки и распаковки данных...
 - Для определения необходимого размера буфера для упаковки может быть использована функция:

- После упаковки всех необходимых данных подготовленный буфер может быть использован в функциях передачи данных с указанием типа MPI_PACKED,
- После получения сообщения с типом *MPI_PACKED* данные могут быть распакованы при помощи функции:

```
int MPI_Unpack (void *buf, int bufsize, int *bufpos,
  void *data, int count, MPI_Datatype type, MPI_Comm comm);
```

Производные типы данных в МРІ...

- Формирование сообщений при помощи упаковки и распаковки данных...
 - Вызов функции *MPI_Pack* осуществляется последовательно для упаковки всех необходимых данных. Если в сообщение должны входить данные

```
double a /* адрес 24 */; double b /* адрес 40 */; int n /* адрес 48 */; то для их упаковки необходимо выполнить:
```

```
bufpos = 0;
MPI_Pack(a,1,MPI_DOUBLE,buf,buflen,&bufpos,comm);
MPI_Pack(b,1,MPI_DOUBLE,buf,buflen,&bufpos,comm);
MPI_Pack(n,1,MPI_INT,buf,buflen,&bufpos,comm);
```

Для распаковки упакованных данных необходимо выполнить:

```
bufpos = 0;
MPI_Unpack(buf,buflen,&bufpos,a,1,MPI_DOUBLE,comm);
MPI_Unpack(buf,buflen,&bufpos,b,1,MPI_DOUBLE,comm);
MPI_Unpack(buf,buflen,&bufpos,n,1,MPI_INT,comm);
```

Производные типы данных в МРІ

- Формирование сообщений при помощи упаковки и распаковки данных:
 - Данный подход приводит к необходимости дополнительных действий по упаковке и распаковке данных,
 - Он может быть оправдан при сравнительно небольших размерах сообщений и при малом количестве повторений,
 - Упаковка и распаковка может оказаться полезной при явном использовании буферов для буферизованного способа передачи данных.

Заключение...

- Во второй презентации раздела рассмотрены имеющиеся в MPI операции передачи данных между двумя процессами, а также возможные режимы выполнения этих операций.
- Обсуждается вопрос организации неблокирующих обменов данными между процессами.
- Подробно рассмотрены коллективные операции передачи данных.
- Представлены все основные способы конструирования и использования производных типов данных в MPI.

Вопросы для обсуждения

- Достаточность состава поддерживаемых в MPI операций передачи данных.
- Рекомендации по использованию разных способов конструирования типов данных.

Темы заданий для самостоятельной работы...

• Операции передачи данных между двумя процессами

- 1. Подготовьте варианты ранее разработанных программ с разными режимами выполнения операций передачи данных. Сравните время выполнения операций передачи данных при разных режимах работы.
- 2. Подготовьте варианты ранее разработанных программ с использованием неблокирующего способа выполнения операций передачи данных. Оцените необходимое количество вычислительных операций, для того чтобы полностью совместить передачу данных и вычисления. Разработайте программу, в которой бы полностью отсутствовали задержки вычислений изза ожидания передаваемых данных.
- 3. Выполните задание 3 с использованием операции одновременного выполнения передачи и приема данных. Сравните результаты вычислительных экспериментов.

Темы заданий для самостоятельной работы...

- Коллективные операции передачи данных
 - 4. Разработайте программу-пример для каждой имеющейся в MPI коллективной операции.
 - 5. Разработайте реализации коллективных операций при помощи парных обменов между процессами. Выполните вычислительные эксперименты и сравните время выполнения разработанных программ и функций МРІ для коллективных операций.
 - 6. Разработайте программу, выполните эксперименты и сравните результаты для разных алгоритмов реализации операции сбора, обработки и рассылки данных всех процессам (функция MPI_Allreduce).

Темы заданий для самостоятельной работы

• Производные типы в МРІ

- 7. Разработайте программу-пример для каждого имеющегося в МРІ способа конструирования производных типов данных.
- 8. Разработайте программу-пример с использованием функций упаковки и распаковки данных. Выполните эксперименты и сравните с результатами при использовании производных типов данных.
- 9. Разработайте производные типы данных для строк, столбцов, диагоналей матриц.
- 10. Разработайте программу-пример для каждой из рассмотренных функций для управления процессами и коммуникаторами.
- 11. Разработайте программу для представления множества процессов в виде прямоугольной решетки. Создайте коммуникаторы для каждой строки и столбца процессов. Выполните коллективную операцию для всех процессов и для одного из созданных коммуникаторов. Сравните время выполнения операции.
- 12. Изучите самостоятельно и разработайте программы-примеры для передачи данных между процессами разных коммуникаторов.

Ссылки

- Информационный ресурс Интернет с описанием стандарта MPI: http://www.mpiforum.org
- Одна из наиболее распространенных реализаций MPI библиотека MPICH представлена на http://www-unix.mcs.anl.gov/mpi/mpich
- Библиотека MPICH2 с реализацией стандарта MPI-2 содержится на http://www-unix.mcs.anl.gov/mpi/mpich2
- Русскоязычные материалы о MPI имеются на сайте http://www.parallel.ru

Литература...

- Гергель В.П. (2007). Теория и практика параллельных вычислений. М.: Интернет-Университет, БИНОМ. Лаборатория знаний.
- **Воеводин** В.В., Воеводин Вл.В. (2002). Параллельные вычисления. СПб.: <u>БХВ-Петербург</u>.
- **Немнюгин** С., Стесик О. (2002). Параллельное программирование для многопроцессорных вычислительных систем СПб.: БХВ-Петербург.
- Group, W., Lusk, E., Skjellum, A. (1994). Using MPI. Portable Parallel Programming with the Message-Passing Interface. –MIT Press.
- **Group**, W., Lusk, E., Skjellum, A. (1999a). Using MPI 2nd Edition: Portable Parallel Programming with the Message Passing Interface (Scientific and Engineering Computation). MIT Press.

Литература

- **Group**, W., Lusk, E., Thakur, R. (1999b). Using MPI-2: Advanced Features of the Message Passing Interface (Scientific and Engineering Computation). MIT Press.
- Pacheco, P. (1996). Parallel Programming with MPI. Morgan Kaufmann.
- Quinn, M. J. (2004). Parallel Programming in C with MPI and OpenMP. New York, NY: McGraw-Hill.
- Snir, M., Otto, S., Huss-Lederman, S., Walker, D., Dongarra, J. (1996). MPI: The Complete Reference. -MIT Press, Boston, 1996.